
Lab 3 · Tema 3

Formulación de casos de IA en una operadora

Caso transversal: operador de telecomunicaciones

Entorno: AWS Academy Learner Lab

Servicios: Amazon S3 · Amazon Athena · Amazon SageMaker Canvas

Duración estimada: 150-180 minutos · Nivel: inicial-intermedio

1. Idea general del laboratorio

Este laboratorio corresponde al Tema 3 y es el primero de la asignatura que se asoma a la inteligencia artificial. Sin embargo, no empieza entrenando ningún modelo. Su objetivo es anterior y más importante: aprender a formular correctamente casos de IA antes de elegir ninguna técnica. En proyectos reales, la mayoría de los fracasos no se deben a un mal algoritmo, sino a un problema mal formulado: se entrena un modelo para predecir algo que no era lo que el negocio necesitaba, o se confunde una correlación con una causa, o se automatiza una decisión que nunca debió automatizarse.

Partimos de una situación habitual. La dirección de la operadora dice: "queremos usar IA para mejorar nuestro servicio y reducir el abandono". Esa frase, tal cual, no es un proyecto: es un deseo. El trabajo del analista consiste en traducir ese deseo genérico en una cartera de casos de IA concretos, viables, medibles y responsables. Para cada caso habrá que decidir qué tipo de problema es (clasificación, regresión, clustering, detección de anomalías, procesamiento de texto), qué variable objetivo tiene, qué datos lo alimentan, qué métrica define el éxito y qué riesgos implica.

Trabajaremos sobre una tabla de clientes de la operadora —heredera directa de la tabla `customer_360` que construimos en el Lab 2, aquí enriquecida con variables objetivo y con el texto del último ticket—. La exploraremos en Athena, formularemos cinco casos de IA distintos, los priorizaremos con una matriz, y opcionalmente construiremos un primer prototipo no-code de predicción de abandono en Amazon SageMaker Canvas, no para obtener el mejor modelo posible, sino para recorrer el ciclo completo y discutir sus límites.

Objetivos didácticos

Al finalizar el lab, el alumno debe ser capaz de:

1. Distinguir una necesidad de negocio de un problema de IA bien formulado.
2. Formular casos de clasificación, regresión, clustering, detección de anomalías y análisis de texto a partir de un mismo conjunto de datos.
3. Identificar, para cada caso, la variable objetivo, las variables predictoras, la métrica técnica y la métrica de negocio.
4. Explorar el dataset en Athena para comprobar la viabilidad de cada caso.
5. Priorizar los casos con una matriz que combine valor, viabilidad, riesgo y explicabilidad.
6. Construir, opcionalmente, un primer modelo no-code en SageMaker Canvas y leer críticamente sus métricas.
7. Separar predicción de causalidad y reconocer los riesgos sistémicos de cada caso.

Conexión con la serie de laboratorios

La serie avanza de forma encadenada: el Lab 1 inventarió las trazas, el Lab 2 las limpió e integró en una tabla de cliente, y este Lab 3 utiliza esa base depurada para decidir qué tiene sentido pedirle a la IA. El Lab 4 entrenará en profundidad el caso que aquí se seleccione como prioritario (la predicción de churn). Por eso este laboratorio es la bisagra entre la ingeniería de

datos y la inteligencia artificial: aquí no se construye el modelo, se decide qué modelo merece construirse.

2. Contexto, servicios y dataset

El sistema observado

La operadora opera en seis regiones (Madrid, Barcelona, Valencia, Sevilla, Bilbao y Zaragoza) y arrastra varios problemas abiertos: aumento del abandono de clientes, saturación del call center, reclamaciones por baja velocidad, incidencias técnicas repetidas, dificultad para priorizar tickets y zonas con peor calidad percibida. La pregunta central del laboratorio es: ¿cómo traducimos la petición genérica de "usar IA" en casos concretos sobre este sistema?

Servicios AWS utilizados

Servicio	Función en el laboratorio
Amazon S3	Almacenar el dataset de casos de IA y los datos preparados para Canvas.
Amazon Athena	Explorar el dataset y comprobar la viabilidad de cada caso con SQL.
Amazon SageMaker Canvas (opcional)	Construir un primer modelo de predicción de churn sin escribir código.

Tabla 1. Servicios AWS empleados en el Lab 3.

Dataset de partida

Se proporciona un único fichero, `telco_ai_cases_lab3.csv` (800 filas, una por cliente), ya limpio. Es la evolución de la tabla `customer_360` del Lab 2, enriquecida con tres variables objetivo (`churn`, `high_priority_ticket`, `network_anomaly`), una variable continua (`satisfaction_score`) y el texto del último ticket. Estas columnas adicionales son lo que permite formular distintos tipos de caso de IA sobre los mismos clientes.

Campo	Descripción	Posible uso
<code>customer_id</code>	Identificador de cliente	Clave, no predictor
<code>region</code>	Región geográfica	Predictor (con cautela)
<code>contract_type</code>	Tipo de contrato	Predictor
<code>monthly_price</code>	Cuota mensual	Predictor
<code>customer_tenure_months</code>	Antigüedad en meses	Predictor
<code>avg_download_speed</code>	Velocidad real media	Predictor / calidad
<code>expected_download_speed</code>	Velocidad contratada	Predictor / calidad
<code>service_interruptions_30d</code>	Interrupciones en 30 días	Predictor
<code>interruption_minutes_30d</code>	Minutos sin servicio	Predictor
<code>num_tickets_30d</code>	Tickets abiertos	Predictor

Campo	Descripción	Posible uso
num_complaints_30d	Reclamaciones	Predictor
call_center_contacts_30d	Contactos call center	Predictor
avg_resolution_hours	Resolución media	Predictor
satisfaction_score	Satisfacción (1-10)	Objetivo (regresión) o predictor
last_ticket_text	Texto del último ticket	Objetivo de NLP
churn	1 = abandona, 0 = permanece	Objetivo (clasificación)
high_priority_ticket	1 = ticket prioritario	Objetivo (clasificación)
network_anomaly	1 = anomalía técnica	Objetivo (anomalías)

Tabla 2. Diccionario del dataset telco_ai_cases_lab3.csv.

Nota. El dataset combina, en una sola tabla, variables predictoras y tres etiquetas distintas. Esto es habitual en un entorno docente, pero en producción cada caso de IA suele tener su propia tabla de entrenamiento, derivada de la capa preparada.

3. Preparación del entorno y carga

Paso 3.1. Iniciar AWS Academy

1. Abre el Learner Lab, pulsa Start Lab y espera al círculo verde.
2. Pulsa AWS para abrir la consola y confirma la región us-east-1.

Paso 3.2. Crear bucket y subir el dataset

Crea un bucket (por ejemplo unir-lab3-telco-ia-<iniciales>-<año>) con estas carpetas:

```
raw/  
athena-results/  
prepared/
```

Sube telco_ai_cases_lab3.csv a la carpeta raw/.

Paso 3.3. Configurar Athena y crear la tabla

Configura la ubicación de resultados en s3://<tu-bucket>/athena-results/ y crea la base de datos y la tabla:

```
CREATE DATABASE IF NOT EXISTS unir_telco_lab3;
```

Con unir_telco_lab3 seleccionada, crea la tabla externa:

```
CREATE EXTERNAL TABLE IF NOT EXISTS telco_ai_cases (  
    customer_id          string,  
    region               string,  
    contract_type        string,  
    monthly_price        double,  
    customer_tenure_months int,  
    avg_download_speed    double,  
    expected_download_speed double,  
    service_interruptions_30d int,  
    interruption_minutes_30d double,  
    num_tickets_30d       int,  
    num_complaints_30d    int,  
    call_center_contacts_30d int,  
    avg_resolution_hours  double,  
    satisfaction_score     double,  
    last_ticket_text      string,  
    churn                 int,  
    high_priority_ticket  int,  
    network_anomaly       int  
)  
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'  
WITH SERDEPROPERTIES ('separatorChar'=',', 'quoteChar'='\"', 'escapeChar'='\\')  
STORED AS TEXTFILE  
LOCATION 's3://<tu-bucket>/raw/'  
TBLPROPERTIES ('skip.header.line.count'='1');
```

Verifica la carga:

```
SELECT COUNT(*) AS total FROM telco_ai_cases;
```

```
SELECT * FROM telco_ai_cases LIMIT 10;
```

Buena práctica. Como los datos provienen del Lab 2 (ya limpios), aquí no repetimos el perfilado. Si usaras un dataset crudo, deberías volver a la fase de calidad antes de formular nada.

Parte A. De la necesidad de negocio al problema de IA

Antes de tocar los datos, conviene fijar el marco conceptual. Una necesidad de negocio es una aspiración ("reducir el abandono"); un problema de IA es una formulación precisa que una máquina puede aprender a resolver ("predecir, para cada cliente, la probabilidad de que se dé de baja en los próximos 30 días, a partir de su historial de calidad y soporte"). La siguiente tabla muestra el salto.

Pregunta de negocio	Posible formulación de IA	Tipo
¿Qué clientes se irán?	Predecir churn por cliente	Clasificación binaria
¿Quién está más insatisfecho?	Predecir satisfaction_score	Regresión
¿Qué tickets son urgentes?	Predecir high_priority_ticket	Clasificación binaria
¿Dónde hay comportamiento raro?	Detectar network_anomaly	Detección de anomalías
¿Qué grupos de clientes hay?	Segmentar clientes	Clustering (no supervisado)
¿De qué se quejan?	Analizar last_ticket_text	NLP / clasificación de texto
¿Qué causa el abandono?	No basta con IA predictiva	Requiere análisis causal (Lab 9)

Tabla 3. De la pregunta de negocio al problema de IA.

Atención. Observa la última fila: no todo problema de negocio es un problema de IA predictiva. Preguntar "qué causa el abandono" es una pregunta causal, no predictiva. Confundir ambas es uno de los errores más frecuentes y se aborda en el Lab 9.

Componentes de una buena formulación

Para considerarse bien formulado, un caso de IA debe responder, como mínimo, a estas preguntas:

- ¿Qué decisión de negocio se quiere apoyar? (no "qué modelo", sino "qué decisión").
- ¿Cuál es la variable objetivo y está disponible y bien definida?
- ¿Qué variables predictoras tienen sentido y están disponibles sin fuga de información?
- ¿Cuál es la métrica técnica de éxito y cuál la métrica de negocio?
- ¿Qué pasa si el modelo se equivoca? ¿Quién supervisa la decisión?

Parte B. Exploración de viabilidad en Athena

Un caso de IA solo es viable si los datos sostienen el patrón que queremos aprender. Antes de formular, exploramos. Estas consultas comprueban que las variables objetivo tienen señal y que se relacionan con las predictoras de forma razonable.

Paso B.1. Equilibrio de las variables objetivo

Un modelo de clasificación necesita suficientes ejemplos de cada clase. Veamos la proporción de cada etiqueta:

```
SELECT
  ROUND(AVG(churn) * 100, 1)           AS pct_churn,
  ROUND(AVG(high_priority_ticket) * 100, 1) AS pct_prioritarios,
  ROUND(AVG(network_anomaly) * 100, 1)   AS pct_anomalias
FROM telco_ai_cases;
```

Preguntas: ¿alguna etiqueta está muy desequilibrada (por ejemplo, menos del 5 %)? Un fuerte desequilibrio no impide el modelado, pero exige técnicas específicas y métricas adecuadas (no basta la accuracy).

Paso B.2. ¿Tiene señal el churn? Contraste de medias

Si el churn fuera impredecible, los clientes que abandonan y los que permanecen tendrían perfiles idénticos. Comprobémoslo:

```
SELECT
  churn,
  COUNT(*)           AS clientes,
  ROUND(AVG(satisfaction_score), 2) AS satisfaccion_media,
  ROUND(AVG(service_interruptions_30d), 2) AS interrupciones_medias,
  ROUND(AVG(num_complaints_30d), 2) AS reclamaciones_medias,
  ROUND(AVG(avg_resolution_hours), 2) AS resolucion_media,
  ROUND(AVG(customer_tenure_months), 1) AS antiguedad_media
FROM telco_ai_cases
GROUP BY churn;
```

Si los promedios difieren claramente entre churn=1 y churn=0, hay señal: el caso es viable.

Preguntas: ¿qué variable separa mejor a los dos grupos? ¿La satisfacción, las interrupciones, la antigüedad?

Paso B.3. Calidad técnica por región

Para el caso de anomalías y para entender el sistema, miramos la brecha entre velocidad contratada y real por región:

```
SELECT
  region,
  ROUND(AVG(expected_download_speed - avg_download_speed), 1) AS brecha_media,
  ROUND(AVG(service_interruptions_30d), 2) AS interrupciones_medias,
  ROUND(AVG(satisfaction_score), 2) AS satisfaccion_media,
  ROUND(AVG(churn) * 100, 1) AS pct_churn
FROM telco_ai_cases
```

```
GROUP BY region
ORDER BY brecha_media DESC;
```

Atención. Si observas que la región con mayor brecha de velocidad es también la de mayor churn, has encontrado una correlación interesante. Pero recuerda: correlación no es causa. Quizá ambas dependan de una inversión en red insuficiente en esa zona. Lo discutiremos en la Parte D.

Paso B.4. Relación entre tickets prioritarios y su contexto

```
SELECT
  high_priority_ticket,
  COUNT(*)                AS casos,
  ROUND(AVG(num_tickets_30d), 2) AS tickets_medios,
  ROUND(AVG(num_complaints_30d), 2) AS reclamaciones_medias,
  ROUND(AVG(call_center_contacts_30d), 2) AS contactos_medios
FROM telco_ai_cases
GROUP BY high_priority_ticket;
```

Parte C. Formulación de cinco casos de IA

Con la exploración hecha, formulamos cinco casos. Cada uno se presenta con su ficha mínima. El alumno deberá completar y discutir estas fichas en el entregable.

Caso 1. Predicción de churn (clasificación)

- Decisión que apoya: activar acciones de retención sobre los clientes en riesgo.
- Variable objetivo: churn.
- Predictoras: `satisfaction_score`, `service_interruptions_30d`, `num_complaints_30d`, `avg_resolution_hours`, `customer_tenure_months`, `contract_type`, `monthly_price`.
- Métrica técnica: recall y F1 (importa no dejar escapar a quien se va). Métrica de negocio: tasa de retención y coste de las acciones.
- Riesgo: tratar mejor solo a quien amenaza con irse; actuar comercialmente cuando el problema es técnico.

Caso 2. Predicción de satisfacción (regresión)

- Decisión que apoya: anticipar caídas de satisfacción antes de que se traduzcan en reclamación o baja.
- Variable objetivo: `satisfaction_score` (continua).
- Predictoras: interrupciones, minutos sin servicio, resolución media, brecha de velocidad, número de contactos.
- Métrica técnica: error absoluto medio (MAE). Métrica de negocio: detección temprana de clientes en deterioro.
- Riesgo: usar `satisfaction_score` como predictor de churn y a la vez como objetivo aquí crearía dependencia circular; cuidado con el orden de los modelos.

Caso 3. Priorización de tickets (clasificación)

- Decisión que apoya: ordenar la cola de soporte cuando no se puede atender todo con la misma urgencia.
- Variable objetivo: `high_priority_ticket`.
- Predictoras: `num_tickets_30d`, `num_complaints_30d`, `call_center_contacts_30d`, interrupciones, `last_ticket_text`.
- Métrica técnica: precisión en la clase prioritaria. Métrica de negocio: reducción del tiempo de resolución de casos graves.
- Riesgo: priorizar sistemáticamente a clientes premium; penalizar a quien reclama menos por desconocimiento o vulnerabilidad.

Caso 4. Detección de anomalías de red

- Decisión que apoya: dirigir el mantenimiento técnico hacia nodos o zonas con comportamiento anómalo.

- Variable objetivo: network_anomaly (si hay etiqueta) o detección no supervisada (si no la hubiera).
- Predictoras: brecha de velocidad, interrupciones, minutos sin servicio, región.
- Métrica técnica: recall de anomalías reales. Métrica de negocio: incidencias evitadas, tiempo de inactividad reducido.
- Riesgo: confundir anomalía estadística con fallo real; sobreactuar ante datos ruidosos.

Caso 5. Análisis de texto de tickets (NLP)

- Decisión que apoya: entender automáticamente de qué se queja la gente y detectar temas emergentes.
- Entrada: last_ticket_text. Salidas posibles: tipo de problema, servicio afectado, urgencia, sentimiento.
- Métrica técnica: exactitud de clasificación frente a una muestra etiquetada a mano. Métrica de negocio: rapidez en detectar incidencias masivas.
- Riesgo: inventar información que el texto no contiene; clasificar mal ironías o ambigüedades. Se desarrolla a fondo en el Lab 8.

Consulta de apoyo para el Caso 5

Para inspeccionar el texto y su relación con el sentimiento implícito:

```
SELECT churn, satisfaction_score, last_ticket_text
FROM telco_ai_cases
WHERE satisfaction_score <= 4
ORDER BY satisfaction_score
LIMIT 15;
```

Parte D. Priorización de los casos

No todos los casos merecen abordarse a la vez. Los priorizamos con una matriz que combina cuatro dimensiones: valor de negocio, viabilidad de datos, riesgo ético-sistémico y facilidad de explicación. La escala es 1 (bajo), 2 (medio), 3 (alto).

Caso	Valor	Viabilidad	Riesgo	Explicabilidad	Prioridad
Churn	3	3	2	2	Alta
Satisfacción	2	3	2	2	Media
Tickets prioritarios	3	2	3	2	Media
Anomalías de red	3	2	2	3	Alta
Texto de tickets	2	3	2	2	Media

Tabla 4. Matriz de priorización (valores orientativos a discutir).

Una fórmula sencilla para ordenar: $\text{Prioridad} = \text{Valor} + \text{Viabilidad} + \text{Explicabilidad} - \text{Riesgo}$. El alumno debe completar su propia matriz y justificar las puntuaciones; las de la tabla son solo un punto de partida para el debate.

Caso elegido para prototipar

Para este laboratorio prototiparemos el caso de churn, por cuatro razones: tiene variable objetivo clara y disponible, es una clasificación binaria fácil de interpretar, conecta con el problema de negocio central de la operadora y permite discutir con riqueza los falsos positivos, los falsos negativos y la diferencia entre predicción y causa. Además, es el caso que el Lab 4 desarrollará en profundidad, de modo que aquí dejamos preparado el terreno.

Parte E. Preparar el dataset para SageMaker Canvas

Para prototipar el churn necesitamos una vista limpia con las columnas relevantes y sin las que provocarían fuga de información o no aportan patrón. Quitamos `customer_id` (identificador), `last_ticket_text` (texto, lo trataría el Lab 8) y las otras dos etiquetas (`high_priority_ticket`, `network_anomaly`) para no mezclar objetivos.

Paso E.1. Crear la vista para churn

```
CREATE OR REPLACE VIEW telco_churn_canvas_view AS
SELECT
  region,
  contract_type,
  monthly_price,
  customer_tenure_months,
  avg_download_speed,
  expected_download_speed,
  (expected_download_speed - avg_download_speed) AS speed_gap,
  service_interruptions_30d,
  interruption_minutes_30d,
  num_tickets_30d,
  num_complaints_30d,
  call_center_contacts_30d,
  avg_resolution_hours,
  satisfaction_score,
  churn
FROM telco_ai_cases;
```

Comprueba la vista:

```
SELECT * FROM telco_churn_canvas_view LIMIT 10;
```

Paso E.2. Materializar a S3 para Canvas

Generamos una tabla física en la zona prepared, que Canvas podrá importar desde S3:

```
CREATE TABLE telco_churn_canvas_data
WITH (
  external_location = 's3://<tu-bucket>/prepared/telco_churn_canvas_data/',
  format = 'PARQUET'
) AS
SELECT * FROM telco_churn_canvas_view;
```

Buena práctica. Si Canvas en tu entorno de AWS Academy no lee bien el Parquet generado por CTAS, una alternativa sencilla es ejecutar la consulta de la vista, descargar el resultado como CSV desde Athena (botón Download results) y subir ese CSV a Canvas directamente.

Parte F. (Opcional) Prototipo en SageMaker Canvas

Atención. La disponibilidad de SageMaker Canvas depende de la configuración de AWS Academy. Si no está disponible o agota crédito, esta parte puede sustituirse por una reflexión escrita sobre cómo sería el ciclo de modelado y qué métricas se revisarían. El valor didáctico del lab no depende de completar Canvas.

Paso F.1. Abrir Canvas e importar datos

1. En la consola, busca SageMaker AI y abre Canvas (puede estar dentro de SageMaker Studio según el entorno).
2. En Datasets, pulsa Import data y elige Amazon S3 como fuente.
3. Navega a `s3://<tu-bucket>/prepared/telco_churn_canvas_data/` (o sube el CSV descargado de Athena) e importa.

Paso F.2. Crear el modelo

4. Pulsa Create model y nómbralo `telco_churn_prediction_lab3`.
5. Tipo de problema: Predictive analysis (Canvas detectará que churn es clasificación binaria).
6. Selecciona el dataset importado y, como Target column, elige churn.

Paso F.3. Revisar columnas antes de entrenar

Canvas muestra una previsualización. Revisa qué columnas conviene usar y cuáles tratar con cautela:

Columna	¿Usar?	Comentario
region	Con cautela	Puede capturar desigualdad de servicio; riesgo de discriminación territorial
contract_type	Sí	Relevante comercialmente
monthly_price	Sí	Variable económica
speed_gap	Sí	Diferencia entre promesa y experiencia
service_interruptions_30d	Sí	Calidad técnica
num_complaints_30d	Sí	Fricción del cliente
satisfaction_score	Con cautela	Muy cerca del resultado: posible fuga de información
churn	Objetivo	No es predictor

Tabla 5. Revisión crítica de columnas para el modelo de churn.

Atención. `satisfaction_score` está tan correlacionada con el abandono que el modelo podría "hacer trampa" apoyándose casi solo en ella. Conviene probar el modelo con y sin esa variable y comparar: es una lección clave sobre fuga de información (data leakage).

Paso F.4. Entrenar y leer las métricas

7. Selecciona Quick build (suficiente para un prototipo; el objetivo no es el mejor modelo, sino recorrer el ciclo).
8. Cuando termine, revisa: accuracy, precision, recall, F1, matriz de confusión e importancia de variables.

Preguntas para el alumno: ¿qué variable resulta más importante? ¿Qué error es más grave en este caso, un falso positivo o un falso negativo? ¿El modelo serviría para decidir de forma automática o solo como apoyo?

Paso F.5. Falsos positivos y falsos negativos

Resultado	Significado	Consecuencia
Falso positivo	Predice baja, pero el cliente se queda	Coste comercial innecesario (descuento regalado)
Falso negativo	Predice permanencia, pero se va	Pérdida real de cliente: no se actuó a tiempo
Verdadero positivo	Detecta correctamente al que se va	Oportunidad de retención
Verdadero negativo	Detecta correctamente al estable	No requiere acción

Tabla 6. Interpretación de errores en el modelo de churn.

Parte G. Evaluación crítica: predicción no es causa

Esta es la parte más importante del laboratorio, aunque no requiera ejecutar nada. Un modelo de churn puede identificar clientes con alta probabilidad de abandono, pero no demuestra que las variables más importantes sean causas del abandono.

Paso G.1. El ejemplo de los tickets

Supongamos que `num_complaints_30d` aparece como variable muy importante. Esto no significa, sin más, que "reclamar causa el abandono". Puede significar que una mala calidad técnica genera a la vez reclamaciones y abandono (causa común no observada), o que los clientes ya decididos a irse reclaman más antes de marcharse. Actuar sobre el síntoma (por ejemplo, dificultar las reclamaciones) en lugar de sobre la causa (mejorar la red) sería contraproducente.

Paso G.2. Riesgos sistémicos a vigilar

Riesgo	Ejemplo en la operadora
Automatización excesiva	Ofrecer descuentos automáticos sin resolver el fallo de red real
Sesgo territorial	Penalizar zonas históricamente peor atendidas usando <code>region</code> como predictor
Variable proxy	<code>contract_type</code> o <code>region</code> funcionando como sustituto de renta o clase social
Bucle de retroalimentación	Atender solo a clientes en riesgo alto y degradar el servicio del resto
Fuga de información	Usar <code>satisfaction_score</code> , casi equivalente al resultado, como predictor
Opacidad	No saber explicar por qué se marca a un cliente como "en riesgo"

Tabla 7. Riesgos sistémicos de los casos formulados.

Paso G.3. Supervisión humana

Para cada caso, el alumno debe indicar qué supervisión humana es necesaria antes de actuar. Por ejemplo: el churn requiere revisión comercial y técnica antes de contactar al cliente; las anomalías de red, confirmación del equipo técnico; el análisis de texto, revisión de muestras y errores. Ningún caso de este laboratorio debería desembocar en una decisión totalmente automática sin persona en el bucle.

Parte H. Entregable del alumno

El alumno entregará un documento de entre cinco y siete páginas con:

1. Descripción del problema telco y mapa de los datos disponibles.
2. Resultado de la exploración de viabilidad en Athena (consultas + interpretación), incluyendo el contraste de medias por churn.
3. Las cinco fichas de caso de IA completas (decisión, objetivo, predictoras, métricas técnica y de negocio, riesgos, supervisión).
4. Matriz de priorización propia, con puntuaciones justificadas y caso elegido.
5. Si se realiza el prototipo: capturas de las métricas de Canvas y comparación del modelo con y sin satisfaction_score (data leakage).
6. Reflexión sobre predicción frente a causa, riesgos sistémicos y supervisión humana necesaria.
7. Conclusión: cuándo conviene usar IA en la operadora y cuándo no.

Plantilla de ficha de caso de IA

Nombre del caso:
 Decisión de negocio que apoya:
 Tipo de IA:
 Variable objetivo:
 Variables predictoras:
 Métrica técnica:
 Métrica de negocio:
 Riesgos:
 Supervisión humana:
 ¿Se recomienda prototipar? (Sí / No) y por qué:

Criterios de evaluación

Criterio	Peso	Insuficiente	Aceptable	Excelente
Exploración de viabilidad	20%	No explora	Explora lo básico	Contrasta señal y justifica viabilidad
Formulación de casos	25%	Fichas incompletas	Cinco casos correctos	Objetivo, métricas y riesgos bien definidos
Priorización	15%	Sin criterio	Matriz completada	Justifica puntuaciones y trade-offs
Prototipo / alternativa	15%	Ausente	Ciclo recorrido	Lee métricas y discute data leakage
Predicción vs causa	15%	Las confunde	Las distingue	Ejemplos propios y riesgos sistémicos
Conclusión y formato	10%	Pobre	Clara	Matizada, profesional, bien citada

Tabla 8. Criterios y rúbrica de evaluación.

Parte I. Limpieza de recursos y cierre

Paso I.1. Eliminar objetos de Athena

```
DROP TABLE IF EXISTS telco_churn_canvas_data;  
DROP VIEW IF EXISTS telco_churn_canvas_view;  
DROP TABLE IF EXISTS telco_ai_cases;  
DROP DATABASE IF EXISTS unir_telco_lab3;
```

Paso I.2. Cerrar Canvas y vaciar S3

- Si usaste Canvas, cierra la sesión (Log out) para que no siga consumiendo crédito; este punto es importante en AWS Academy.
- Vacía y elimina el bucket si no vas a reutilizarlo, o conserva la zona prepared para encadenar con el Lab 4.

Paso I.3. End Lab

1. Pulsa End Lab en el Learner Lab y verifica que el círculo pasa a rojo.

Atención. SageMaker Canvas puede seguir generando coste si la sesión queda abierta aunque termines el lab. Asegúrate siempre de hacer Log out de Canvas antes de End Lab.

Cierre didáctico

Has recorrido el camino que separa un deseo de negocio ("usar IA para mejorar") de una cartera de casos concretos, viables y responsables. Has aprendido que formular es más importante que algoritmizar: que antes de elegir una técnica hay que decidir qué decisión se quiere apoyar, qué variable la representa, qué datos la sostienen y qué riesgos implica. Y has visto, con un prototipo, que un modelo predictivo es una herramienta de apoyo, no un oráculo: que predecir no es explicar y que ninguna de estas decisiones debería automatizarse sin supervisión humana.

El caso de churn que aquí has seleccionado y dejado preparado será el protagonista del Lab 4, donde lo entrenaremos y evaluaremos en profundidad. Llegamos a ese laboratorio sabiendo no solo cómo construir el modelo, sino por qué construir ese modelo y no otro, y con qué cautelas usarlo.

Referencias y lecturas complementarias

- Amazon Web Services. (2024). Amazon SageMaker Canvas User Guide. <https://docs.aws.amazon.com/sagemaker/latest/dg/canvas.html>
- Amazon Web Services. (2024). Amazon Athena User Guide — Views and CTAS. <https://docs.aws.amazon.com/athena/>
- Kaufman, S., Rosset, S., & Perlich, C. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM TKDD, 6(4).

- Pearl, J., & Mackenzie, D. (2018). The book of why: The new science of cause and effect. Basic Books.
- Provost, F., & Fawcett, T. (2013). Data science for business. O'Reilly Media.
- O'Neil, C. (2016). Weapons of math destruction. Crown.